

Routing wie 1969: Hightowers Line-Search-Algorithmus in Rust

Bilder: alle Abbildungen in diesem Artikel sind Ausgaben der beschriebenen Implementierung. Der SVG-Renderer zeichnet nach, was der Algorithmus protokolliert hat.

Wer einen Diagramm-Editor baut, stößt irgendwann auf ein unscheinbares Problem: Zwei Kästen sollen mit einer rechtwinkligen Linie verbunden werden, und die Linie soll den anderen Kästen ausweichen. Die Aufgabe hat drei Anforderungen, die sich nicht gut vertragen. Der Editor ist interaktiv, also muss die Berechnung schnell sein, im Idealfall so schnell, dass sie beim Verschieben eines Kastens in jedem Frame mitläuft. Die Linie soll ruhig aussehen, also mit wenigen Knicken. Und ob sie die kürzeste ist, interessiert niemanden, solange sie nicht absurd aussieht.

Der Algorithmus, der zu diesem Anforderungsprofil passt, wurde 1969 bei den Bell Labs veröffentlicht, in FORTRAN II für eine IBM 7094 geschrieben und war für das Verlegen von Leiterbahnen auf Platinen gedacht. David W. Hightower nannte ihn *A Solution to Line-Routing Problems on the Continuous Plane* (DOI 10.1145/800260.809014). Ich habe ihn in Rust nachgebaut, und dieser Artikel erklärt, wie er funktioniert, wo er versagt und warum er trotzdem gut zu Diagrammen passt.




Figure 1: Links: Ein Gitter-Flood-Fill (Lee-Algorithmus) färbt Tausende Zellen ein, bevor er den Weg findet. Rechts: Hightowers Algorithmus zeichnet fünf Linien und ist fertig.

Dasselbe Problem, zweimal gelöst. Links besucht die Breitensuche 6361 Gitterzellen, rechts konstruiert Hightowers Algorithmus fünf Linien.

Das Problem, und warum „kürzest“ das falsche Ziel ist

Formal gesehen sind gegeben ein rechteckiges Spielfeld, eine Menge horizontaler und vertikaler Strecken als Hindernisse (ein Rechteck sind einfach vier Strecken) und zwei Punkte A und B. Gesucht ist ein Pfad aus achsenparallelen Segmenten von A nach B, der kein Hindernis berührt.

Der Klassiker dafür ist der Algorithmus von C. Y. Lee aus dem Jahr 1961. Man legt ein Gitter über das Spielfeld, markiert die Zellen unter den Hindernissen als belegt und lässt von A aus eine Breitensuche laufen, bis sie B erreicht. Das ist vollständig, findet garantiert den kürzesten Weg und ist in zehn Zeilen implementiert. Der Haken ist die Auflösung. Hightower rechnet in seinem Paper vor, was passiert, wenn man eine 9×9 Zoll große Platine mit einer Genauigkeit von einem Tausendstel Zoll rastern will, nämlich 81 Millionen Zellen, die man 1969 weder speichern noch durchsuchen konnte. Und selbst heute, wo der Speicher kein Problem mehr ist, wachsen Aufwand und Speicher mit der *Fläche* statt mit der Anzahl der Hindernisse. Ein fast leeres, großes Diagramm ist für die Breitensuche genauso teuer wie ein vollgestopftes.

Der zweite Punkt ist die Optimalität. Für Leiterbahnen wollte Hightower nicht den kürzesten Weg, und für Diagramme will ich ihn auch nicht. Ein kürzester Weg auf dem Gitter zwingt sich gern durch die Lücke zwischen zwei Kästen, wenn das ein paar Einheiten spart, und produziert dabei eine Treppe. Ein etwas längerer Weg mit zwei Knicken sieht in einem Diagramm besser aus, und niemand misst nach.




Figure 2: Links: der kürzeste Pfad mit fünf Knicken durch die Lücke zwischen zwei Rechtecken. Rechts: Hightowers Pfad mit zwei Knicken oben herum.

Kürzest ist nicht hübsch. Links der Gitterpfad mit fünf Knicken und Länge 104, rechts Hightowers Pfad mit zwei Knicken und Länge 142.

Ein Zwischenspiel: Line Search gegen Flood Fill

In der Literatur zum Platinen-Routing heißt Lees Verfahren *maze routing*. Man kann sich den Flood Fill wirklich wie Wasser vorstellen, das sich von A aus durch ein Labyrinth ausbreitet. Die Alternative, die Ende der Sechziger aufkam, heißt *line probing* oder *line search*. Statt Zellen zu fluten, schießt man Linien durch den Raum und schaut, wo sie hängen bleiben. Hightowers Algorithmus ist einer der beiden Klassiker dieser Familie, der andere ist der von Mikami und Tabuchi aus dem Jahr 1968, der vollständig ist, dafür aber mehr Linien braucht.

Das Paper ist auch als Zeitdokument lesenswert. Hightower hat sein Programm auf Platinen losgelassen, auf PERT-Diagramme und auf Labyrinth, darunter das Heckenlabyrinth von Hampton Court. Die Plots im Anhang stammen von einem *Dataplotter* der Electronics Associates Inc., und unter dem Hampton-Court-Bild steht „Total time .0005“ (die Einheit steht nicht dabei, vermutlich Stunden, was zu den Abrechnungsgewohnheiten der Zeit passen würde). Ich habe das Labyrinth nicht exakt nachgebaut, aber ein ähnliches aus konzentrischen Hecken mit versetzten Lücken und ein paar Sackgassen.




Figure 3: Ein Heckenlabyrinth aus konzentrischen Ringen. Der rote Pfad führt vom Eingang unten in die Mitte, die dünnen blauen und grünen Linien sind die Suchlinien der beiden Netze.

Das Labyrinth, gelöst mit 35 Linien in 23 Schritten. Auf meinem Rechner dauert

das etwa 40 Mikrosekunden.

Cover und Escape-Linien

Hightower braucht nur zwei Begriffe, und beide sind anschaulich. Für einen Punkt p nennt er das nächste Hindernis, das p in einer der vier Richtungen den Weg versperrt, ein *Cover*. Eine horizontale Strecke *covert* p , wenn das Lot von p auf die Strecke sie trifft, also wenn p in x-Richtung innerhalb der Strecke liegt. Von allen horizontalen Strecken, die p covern, ist die nächste oberhalb die Decke von p und die nächste unterhalb der Boden. Mit den vertikalen Strecken genauso, das gibt die linke und die rechte Wand.




Figure 4: Ein Punkt p zwischen mehreren Strecken. Vier davon sind schwarz hervorgehoben: die nächste Decke, der nächste Boden, die nächsten Wände links und rechts. Grau gestrichelte Lote zeigen, warum sie p covern.

Die vier schwarzen Strecken covern p und sind seine Cover. Die grauen covern p nicht, weil das Lot von p sie verfehlt.

Die *Escape-Linie* durch p ist dann die längste waagerechte (oder senkrechte) Strecke durch p , die zwischen den Covern Platz hat. Sie ist alles, was p in dieser

Richtung „sieht“. In der Implementierung endet sie eine Einheit vor dem Cover, damit der Pfad später automatisch Abstand zu den Hindernissen hält. Wenn in einer Richtung kein Cover existiert, endet die Linie am Rand des Spielfelds.




Figure 5: Zweiseitige Abbildung. Links ein Punkt p in einer unaufgeräumten Szene, seine vier Cover schwarz, alle anderen Strecken grau. Rechts zusätzlich die beiden blauen Escape-Linien durch p , die kurz vor den Covern enden.

Links die Cover von p , rechts seine beiden Escape-Linien.

Das Schöne an dieser Definition ist, dass man sie ohne Gitter ausrechnen kann. Ich halte die horizontalen Hindernisse in einer **BTreeMap**, deren Schlüssel die y -Koordinate ist, und die vertikalen in einer zweiten mit der x -Koordinate als Schlüssel. Die Decke eines Punktes findet man dann, indem man von seiner y -Koordinate aus nach oben durch die Map läuft und bei der ersten Zeile stehen bleibt, in der eine Strecke die x -Koordinate des Punktes überdeckt. Das ist der Bisektions-Trick aus meinen Notizen, und er sorgt dafür, dass die Kosten von der Anzahl der Hindernisse abhängen und von sonst nichts.

Escape-Punkte: um Ecken schleichen

Die Escape-Linien eines Punktes sind eine Sackgasse, wenn B nicht zufällig auf einer von ihnen liegt. Der Algorithmus muss also um Ecken kommen, und dafür hat Hightower zwei Prozesse.

Prozess I ist der Normalfall. Nehmen wir an, die Decke über dem aktuellen Punkt Z blockiert den Weg nach oben. Wenn die horizontale Escape-Linie von Z über das Ende dieser Decke hinausreicht, gehen wir seitlich bis eine Einheit hinter das Deckenende. Von dort aus kommt eine neue vertikale Escape-Linie an der Decke vorbei nach oben. Der Punkt hinter dem Deckenende ist ein *Escape-Punkt*, die neue Linie wandert ins Netz. Das Gleiche probiert der Algorithmus mit dem

Boden und mit den beiden Wänden, in der Reihenfolge der euklidischen Nähe der Cover-Enden zu Z.




Figure 6: Drei Bilder nebeneinander. Erstes: Punkt Z mit seinen Escape-Linien, die Decke über ihm orange markiert. Zweites: ein Kandidat e eine Einheit rechts vom Ende der Decke, orange eingekreist. Drittes: die neue vertikale Escape-Linie durch e reicht bis zum oberen Rand.

Prozess I in drei Schritten: Die Decke blockiert Z, der Kandidat e liegt eine Einheit hinter dem Deckenende auf der horizontalen Escape-Linie von Z, und die neue Linie durch e kommt an der Decke vorbei.

Prozess II greift, wenn kein Cover-Ende erreichbar ist, etwa weil Z in einer Tasche sitzt. Dann wandert der Algorithmus von den Enden der eigenen Escape-Linien aus Einheit für Einheit zurück in Richtung Z, und an jeder Position versucht er, eine senkrechte Linie abzweigen zu lassen und von dort aus Prozess I anzuwenden. Man kann sich das als Rückzug entlang der Wand vorstellen, bei dem man immer wieder über die Schulter schaut, ob sich eine Lücke auftut.

Prozess II. Das Regal unter der Lücke blockiert Prozess I direkt von Z aus. Der Rückzug nach oben entlang der eigenen Linie findet eine Position, von der es seitlich und dann durch die Lücke weitergeht.

Beide Prozesse folgen einer Regel, die den Algorithmus terminieren lässt und ihn gleichzeitig unvollständig macht. Eine Escape-Linie wird nie zweimal benutzt. Jedes Netz merkt sich alle Linien, die es je gezeichnet hat, und ein Kandidat, dessen Linie schon existiert, wird verworfen. Weil es nur endlich viele verschiedene Escape-Linien gibt (jede ist ein maximales freies Intervall in einer Zeile oder Spalte), geht dem Algorithmus irgendwann der Nachschub aus, und er gibt auf. Was das für die Vollständigkeit heißt, kommt weiter unten.

Zwei Netze wachsen aufeinander zu

Der Algorithmus arbeitet bidirektional. Ein Netz wächst von A aus, das andere von B, und sie kommen abwechselnd an die Reihe. Ein Zug besteht darin, die Escape-Linie durch den aktuellen Punkt zu zeichnen, sie gegen alle senkrecht dazu stehenden Linien des anderen Netzes zu testen und dann den nächsten




Figure 7: Zwei Bilder. Links: Z sitzt in einer Tasche mit Deckel, der eine Lücke hat, aber ein kleines Regal direkt unter der Lücke versperrt den direkten Weg. Ein kleiner blauer Punkt oben auf der vertikalen Escape-Linie von Z markiert die Rückzugsposition, von der ein Prozess-I-Schritt seitlich möglich wird. Rechts: der fertige Pfad, der oben durch die Lücke führt.

Escape-Punkt zu suchen. Sobald eine Linie des einen Netzes eine Linie des anderen kreuzt, gibt es einen Pfad. Er läuft vom Kreuzungspunkt entlang der einen Linie zu ihrem Escape-Punkt, von dort zu dessen Vorgänger, und so weiter bis A, und auf der anderen Seite genauso bis B.

Das ist die ganze Rekonstruktion. Jeder Escape-Punkt liegt auf einer Escape-Linie seines Vorgängers, teilt sich mit ihm also eine x- oder y-Koordinate. Wenn man die Kette aufschreibt, ist sie automatisch rechtwinklig. In meiner Implementierung sind die Escape-Punkte ein Baum mit Elternzeigern, was den ersten Aufräumschritt aus dem Paper überflüssig macht (Hightower hatte flache Listen und musste erst herausfinden, welche Punkte zwischen welchen liegen).

Ein vollständiger Lauf, Ereignis für Ereignis. Blau ist das Netz von A, grün das von B, der orange Kreis die Kreuzung. Die Farben habe ich aus meinen Whiteboard-Skizzen übernommen.

Der triviale Fall funktioniert dabei von selbst. Im ersten Zug zeichnet jedes Netz beide Escape-Linien durch seinen Startpunkt. Wenn A und B sich in einer freien Zeile oder Spalte sehen, kreuzt schon die vertikale Linie von B die horizontale von A, und der Pfad hat einen Knick oder gar keinen.

Nachbearbeitung

Der Pfad, den man aus den Bäumen abliest, ist gültig, aber nicht immer schön. Escape-Linien sind maximal lang, und ein Kreuzungspunkt liegt gern weiter außen als nötig, sodass der Pfad einen Umweg macht und wieder zurückkommt. High-




Figure 8: Animation: In einer Szene mit neun Rechtecken wachsen blaue Linien von A und grüne von B, Punkte markieren die Escape-Punkte, ein orangefarbener Kreis den Moment der Kreuzung, dann erscheint der rote Pfad.

tower nennt die Reparatur *second improvement* und beschreibt zwei Varianten. Bei der ersten verlängert man jedes Pfadsegment so weit, wie die Hindernisse es zulassen, und wenn die Verlängerung ein späteres, senkrechtes Pfadsegment trifft, schneidet man alles dazwischen heraus. Bei der zweiten schiebt man einen Tastpunkt Einheit für Einheit über jedes Segment und schießt von dort senkrechte Linien ab. Trifft eine davon ein späteres paralleles Segment, wird auch hier abgekürzt. Die zweite Variante ist teurer, weil sie mit der Pfadlänge skaliert, aber sie entfernt Schleifen, die der ersten entgehen.




Figure 9: Zwei Bilder. Links: der Rohpfad mit einem kleinen Haken neben B, der Pfad läuft an B vorbei, biegt ab und kommt zurück. Rechts: derselbe Pfad nach der Verbesserung ohne den Haken.

Links der rohe Pfad aus den Escape-Punkten mit dem Umweg rechts von B, rechts nach der zweiten Verbesserungsvariante.

Nach jeder Verbesserung läuft noch ein Aufräumschritt, der kollineare Punkte zusammenfasst, und im Debug-Build prüft eine Funktion, dass der Pfad wirklich bei A beginnt, bei B endet, nur rechte Winkel hat und kein Hindernis berührt.

Implementierung in Rust

Ein paar Entscheidungen haben sich bewährt. Alle Koordinaten sind `i64`. Es gibt keinen einzigen `Float` im Crate, und damit auch keine Diskussion darüber, ob zwei Linien sich „fast“ schneiden. Eine Einheit ist der Mindestabstand zwischen Pfad und Hindernis, und weil die Escape-Linien eine Einheit vor ihren Covern enden, ergibt sich dieser Abstand ganz von selbst.

Der gesamte Zustand des Algorithmus besteht aus zwei Netzen, und jedes Netz ist ein `Vec` von Escape-Punkten plus ein `Vec` von Linien, ohne Gitter und ohne Matrix. Die Frage „wurde diese Linie schon benutzt?“ ist ein linearer Scan über

die Linien des Netzes, was bei den Dutzenden von Linien, die in typischen Szenen entstehen, schneller ist als jede HashMap.

Jeder Schritt erzeugt ein `TraceEvent` (Linie gezeichnet, Escape-Punkt gefunden, Kreuzung, Rohpfad, verbesserter Pfad). Der SVG-Renderer spielt diese Ereignisse ab, und weil er ein Präfix der Ereignisliste zeichnen kann, fallen die Frames für die Animation oben einfach als Nebenprodukt heraus. Alle Bilder in diesem Artikel sind auf diesem Weg entstanden.

Der Algorithmus selbst (Geometrie, Hindernisse, Netze, Escape-Prozesse, Pfadverbesserung) hat etwa 1400 Zeilen inklusive Unit-Tests, ohne Abhängigkeiten. Die öffentliche API ist absichtlich klein.

```
use hightower::{Bounds, ObstacleSet, Point, route};

let mut obstacles = ObstacleSet::new(Bounds::new(Point::new(0, 0), Point::new(100, 100)));
obstacles.add_rect(Point::new(40, 20), Point::new(60, 80));

let path = route(&obstacles, Point::new(10, 50), Point::new(90, 50));
// Some([(10,50), (10,81), (90,81), (90,50)])
```

Wer mehr wissen will, ruft `route_with` auf und bekommt neben dem Pfad den Grund für das Ende der Suche (gefunden, beide Netze aufgegeben, Schrittlimit) und den vollständigen Trace zurück. Bereits gefundene Pfade lassen sich als Hindernisse eintragen, entweder komplett oder nur ihre Ecken. Letzteres ist Hightowers Modus für PERT-Diagramme: Kreuzungen sind erlaubt, aber keine zwei Pfade dürfen übereinander laufen.

Wo es bricht

Hightower nennt im Paper zwei Nachteile, und beide lassen sich vorführen.

Der erste ist harmlos, der Pfad ist nicht der kürzeste. Im Bild weiter oben war der gefundene Pfad 142 Einheiten lang statt 104. Für Diagramme ist das der gewünschte Kompromiss. Für Platinen schlug Hightower vor, den Algorithmus mehrfach mit leicht veränderten Regeln laufen zu lassen und den kürzesten der Kandidaten zu nehmen.

Der zweite ist ernster. Der Algorithmus kann einen Pfad übersehen, der existiert, und das liegt an der Regel, dass keine Escape-Linie zweimal benutzt wird. Hightower beschreibt den Fall selbst. Wenn das Netz eine Escape-Linie benutzt hat, um durch eine schmale Öffnung in eine Box zu gelangen, kommt es durch dieselbe Öffnung nicht wieder heraus. Er schreibt dazu, in allen seinen Experimenten sei ein Pfad gefunden worden, wenn einer existierte. Ich habe das nachgeprüft, indem ich zufällige Szenen aus Räumen mit Türen erzeugt und jede Antwort gegen die Breitensuche abgeglichen habe (die Breitensuche ist vollständig, deshalb taugt sie als Orakel). Von 16782 lösbaren Szenen hat der Algorithmus 428 nicht gelöst, also etwa 2,5 Prozent. Die kleinste davon hat sieben Strecken:




Figure 10: Eine Box mit einer Lücke von einer Einheit in der rechten Wand, B darin, A oberhalb. Beide Netze haben sich in dem schmalen Streifen rechts neben der Box festgefahren und dort viele kurze Linien gezeichnet. Der graue gestrichelte Pfad, den die Breitensuche gefunden hat, führt links um die Box herum.

Der blinde Fleck. B kommt durch die Lücke rechts aus der Box, A kommt von oben in denselben schmalen Streifen, und dort geben beide Netze auf, weil ihre Linien am Spielfeldrand enden und Hightower von Rändern aus keinen Rückzug vorsieht. Der gestrichelte Weg links herum bleibt unentdeckt.

Der Grund für dieses Beispiel ist ein Detail in Prozess II, das ich zunächst anders implementiert hatte. Hightower definiert die Rückzugspositionen als Schnittpunkte der Escape-Linie mit ihren Covern. Endet die Linie am Spielfeldrand, gibt es kein Cover und damit keinen Rückzug. Meine erste Fassung zog sich auch von Rändern zurück, fand dann auch diese Szene, produzierte aber in offenen Szenen Hunderte Linien, weil sie an einer Linie von Rand zu Rand jede einzelne Position abklapperte. Das ist wieder ein Gitter, nur durch die Hintertür. Im Crate ist diese Variante als Option erhalten. Mit ihr sinkt die Fehlerquote auf etwa 0,5 Prozent, in offenen Szenen zahlt man dafür mit vielen Linien.

Für die Praxis ist Hightower damit eine schnelle Heuristik mit einem Rückfallpfad. So stand es auch in meinen ursprünglichen Notizen für den Diagramm-Editor: erst Hightower, bei None ein A* auf dem Gitter, und Pfade nur dann neu berechnen, wenn sich innerhalb ihrer Bounding Box etwas geändert hat.

Wie schnell ist es?

Ich habe den Algorithmus gegen meine eigene, bewusst naive Breitensuche laufen lassen, auf denselben Szenen mit zufällig platzierten Rechtecken. Die Zahlen sind Mediane über 41 Szenen pro Konfiguration, gemessen auf einem gewöhnlichen Laptop.




Figure 11: Zwei Liniendiagramme mit logarithmischer Zeitachse. Links wächst die Kantenlänge des Spielfelds von 64 auf 2048 bei 20 Hindernissen: die Breitensuche steigt von rund 80 Mikrosekunden auf 90 Millisekunden, Hightower bleibt bei ein bis zwei Mikrosekunden. Rechts wächst die Zahl der Rechtecke von 0 auf 320 bei fester Fläche: die Breitensuche bleibt bei einer halben bis einer Millisekunde, Hightower steigt von 0,4 auf etwa 20 Mikrosekunden.

Links: Die Fläche wächst, die Anzahl der Hindernisse bleibt. Rechts: Die Fläche bleibt, die Hindernisse werden mehr.

Die linke Kurve ist der Grund für diesen Artikel. Bei 20 Rechtecken braucht Hightower ein bis zwei Mikrosekunden pro Route, und es ist ihm egal, ob das Spielfeld 64 oder 2048 Einheiten breit ist. Die Breitensuche skaliert mit der Fläche und landet bei 2048 Einheiten Kantenlänge bei 90 Millisekunden, was für einen interaktiven Editor mit vielen Kanten schon zu langsam wäre. Rechts sieht man den Preis. Mit der Anzahl der Hindernisse wachsen die Kosten bei Hightower, weil jede Cover-Abfrage durch mehr Zeilen läuft und Prozess II mehr Linien probiert. Bei 160 Rechtecken auf 256×256 Einheiten ist die Szene allerdings so voll, dass ein Diagramm-Editor andere Sorgen hätte, und selbst dort liegen wir bei 20 Mikrosekunden gegen 700. Ein ernsthafter A* mit guter Heuristik wäre schneller als mein Flood Fill, aber an der Abhängigkeit von der Fläche würde auch er nichts ändern.

Was noch fehlt

Hightower beschreibt im Paper vier Betriebsmodi für ganze Netzlisten, von „alle Verbindungen ohne Kreuzungen“ bis zur Simulation einer zweiseitigen Platine. Davon habe ich nur den Baustein umgesetzt, dass fertige Pfade zu Hindernissen werden. Die Reihenfolge der Netze (Hightower empfiehlt, mit den kurzen anzufangen) bleibt dem Aufrufer überlassen. Interessant wäre auch, die Unvollständigkeit anzugehen: mehrere Kandidaten pro Escape-Schritt und Backtracking, wenn ein Netz aufgibt. Und wer die Vollständigkeit unbedingt braucht, schaut sich Mikami-Tabuchi an, das mit demselben Linien-Vokabular arbeitet und dafür mehr Linien in Kauf nimmt.

Der Code liegt auf GitHub unter [REPO-URL]. Die Beispiele im Ordner `examples/` erzeugen alle Abbildungen dieses Artikels, das Labyrinth eingeschlossen, und der Benchmark schreibt eine CSV, aus der ein kurzes Python-Skript das Diagramm oben zeichnet.